

信号建模与 算法实践

多高斯混合模型

Xu Weiye

2022-10-31


Content

1	Introduction	2
2	proving	3
3	code	4
4	result	5


1 Introduction

一般的高斯模型如下：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$



但是大部分数据都不是按照如下分布的，但是我们还是可以依照傅里叶展开的思路，将一个分布用高斯分布展开



那么可以将表达式写成多元高斯加权求和的形式

$$p(x) = \frac{1}{\sqrt{(2\pi)^d \det|\Sigma|}} \exp\left[-\frac{1}{2}(x-\mu)\Sigma^{-1}(x-\mu)^T\right]$$

$$p(X) = \sum_{k=1}^K \alpha_k \frac{1}{\sqrt{(2\pi)^d \det|\Sigma_k|}} \exp\left[-\frac{1}{2}(X-\mu_k)\Sigma_k^{-1}(X-\mu_k)^T\right]$$

其中， Σ 是协方差矩阵， α_k 代表属于不同单个高斯分布的概率。

这样就能将单个多元高斯混合在一起表达更加复杂的分布

2 proving

根据最大似然估计

$$L(X | \Theta) = \prod_{i=0}^N p(x_i | \Theta)$$

其中 Θ 是所有分布参数 μ, σ, α 的集合, N 是样本个数。

同时我们取 \log 不影响最大最小值, 那么展开后可以得到,

$$L(X | \Theta) = \sum_{i=0}^N \ln \left[\sum_{k=0}^K \alpha_k \mathcal{N}(X, \mu_k, \sigma_k) \right]$$

对于 μ_k 的推导

$$\begin{aligned} \frac{\partial}{\partial \mu_k} \ln p(\mathbf{X} | \mu, \Sigma, \pi) &= \sum_{n=1}^N \frac{\pi_k}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)} \frac{\partial \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\partial \mu_k} \\ &= - \sum_{n=1}^N \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)} \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) \\ &= - \sum_{n=1}^N \gamma_{nk} \Sigma_k^{-1} (\mathbf{x}_n - \mu_k) = 0 \\ \sum_{n=1}^N \gamma_{nk} (\mathbf{x}_n - \mu_k) &= \sum_{n=1}^N \gamma_{nk} \mathbf{x}_n - N_k \mu_k = 0 \\ \mu_k &= \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} \mathbf{x}_n \\ \text{where: } N_k &= \sum_{n=1}^N \gamma_{nk} \end{aligned}$$

对于 Σ_k 的推导

$$\begin{aligned} \frac{\partial}{\partial \Sigma_k} \ln p(\mathbf{X} | \mu, \Sigma, \pi) &= \sum_{n=1}^N \frac{\pi_k}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)} \frac{\partial \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\partial \Sigma_k} \\ &= \sum_{n=1}^N \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)} \frac{\partial \ln \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\partial \Sigma_k} \\ &= \sum_{n=1}^N \gamma_{nk} \left(\frac{1}{2} \Sigma_k - \frac{1}{2} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \right) \\ &= 0 \\ \Sigma_k &= \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T \end{aligned}$$

对于 π_k 的推导拉格朗日函数:

$$\ln p(\mathbf{X} | \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right)$$

$$\text{s.t.} \quad \sum_{k=1}^K \pi_k = 1$$

求偏导:

$$\sum_{n=1}^N \frac{\mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda = 0$$

两边同乘 π_k 再对 k 求和, 得

$$\lambda = -N$$

代入拉格朗日函数:

$$\sum_{n=1}^N \frac{\gamma_{nk}}{\pi_k} - N = \frac{N_k}{\pi_k} - N = 0$$

$$\hat{\pi}_k = \frac{N_k}{N}$$

3 code

其中 E-STEP 如下:

```
#E-Step
p = np.zeros((N, K))
for k in range(K):
    p[:, k] = alpha[k] * gaussian(X, mu[k], cov[k])
sumP = np.sum(p, axis=1)
omega = p / sumP[:, None]
```

M-STEP 如下:

```
#M-Step
omega_sum = np.sum(omega, axis=0)
alpha = omega_sum / N
for k in range(K):
    omegaX = X * omega[:, [k]]
    mu[k] = np.sum(omegaX, axis=0) / omega_sum[k]

    X_mu_k = X - mu[k]
    omega_X_mu_k = omega[:, [k]] * X_mu_k
    cov[k] = np.dot(np.transpose(omega_X_mu_k), X_mu_k) / omega_sum[k]
```

如果使用 K-means 初始化如下：

```
kmeans = KMeans(  
    n_clusters=K,  
    init='k-means++',  
    n_init=10,  
    max_iter=300)  
kmeans.fit(Y)
```

4 result

Table 1: 测试结果分析

分类超参 K	迭代 2 次	迭代 10 次	迭代 50 次
2	76.39%	76.87%	76.99%
4	76.51%	78.19%	79.52%
8	78.19%	79.28%	80.36%
16	79.88%	79.52%	80.36%